UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE TECNOLOGIA

DEPARTAMENTO DE TELEINFORMÁTICA

CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

PAULO RICARDO MENEZES SOARES

AQUISIÇÃO DE BIOSINAIS

FORTALEZA

2026

PAULO RICARDO MENEZES SOARES

AQUISIÇÃO DE BIOSINAIS

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação do Centro de Tecnologia da Universidade Federal do Ceará, como requisito parcial à obtenção do grau de bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Victor Hugo Costa de Albuquerque

FORTALEZA

2026

PAULO RICARDO MENEZES SOARES

AQUISIÇÃO DE BIOSINAIS

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação do Centro de Tecnologia da Universidade Federal do Ceará, como requisito parcial à obtenção do grau de bacharel em Engenharia de Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Victor Hugo Costa de Albuquerque (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

“O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado.”

(Ariano Suassuna)

RESUMO

ABSTRACT

LISTA DE FIGURAS

LISTA DE TABELAS

LISTA DE SÍMBOLOS

Ae	Área efetiva da antena
B	Largura de faixa em que o ruído é medido em Hertz
d	Distância em metros
E	Campo elétrico
FA	Fator da antena
Gr	Ganho de recepção
h	Altura efetiva ou comprimento efetivo de uma antena
I	Corrente elétrica
k	Constante de Boltzmann's
K	Eficiência de irradiação
M	Variação do patamar de ruído em função da RBW
N	Condutor de neutro
NF	Figura de ruído
Ni	Potência do ruído na entrada
No	Potência do ruído na saída
P	Potência
R	Resistência
Si	Potência do sinal na entrada
So	Potência do sinal na saída
t	Tempo
V	Tensão
ZL	Impedância da antena
Zo	Impedância de referência (50Ω)
λ	Comprimento de onda
Γ	Coeficiente de reflexão

SUMÁRIO

1 INTRODUÇÃO 13

2 TÍTULO DO SEGUNDO CAPÍTULO 14

3 METODOLOGIA 15

3.1 Descrição da Ferramenta MNE 15

3.2 Revisão da Literatura atual e Estado da Arte 15

3.2.1 Eletrocardiograma (ECG) 16

3.2.2 Fotopletismograma (PPG) 16

3.2.3 Sensores Inerciais (IMU) 17

3.2.4 Eletroencefalograma (EEG) e o Modelo LUNA 17

4 RESULTADOS 19

5 CONCLUSÕES E TRABALHOS FUTUROS 20

REFERÊNCIAS 21

1 INTRODUÇÃO

2 TÍTULO DO SEGUNDO CAPÍTULO

3 METODOLOGIA

3.1 Descrição da Ferramenta MNE

O MNE-Python (cuja sigla representa *Magnetoencephalography and Electroencephalography* em Python) é um pacote de código aberto em Python projetado para a exploração, visualização e análise de dados neurofisiológicos humanos. Tornou-se um padrão na pesquisa em neurociência para o processamento de sinais cerebrais devido à sua flexibilidade e abrangência.

O MNE-Python suporta diversos tipos de dados neurofisiológicos, incluindo EEG (*Electroencephalography*), MEG (*Magnetoencephalography*), sEEG (EEG intracraniano), ECoG (*Electrocorticography*) e fNIRS (*Functional Near-Infrared Spectroscopy*). A biblioteca oferece um ecossistema completo de ferramentas que cobrem todas as etapas da pipeline de análise, desde a leitura e importação de dados em diversos formatos até a etapa de pré-processamento, análise e visualização dos resultados.

Entre as principais funcionalidades de pré-processamento, o MNE-Python oferece ferramentas robustas para filtragem digital, detecção de eventos e remoção de artefatos. A remoção de artefatos pode ser realizada por meio de ICA (*Independent Component Analysis*) ou SSP (*Signal Space Projection*), técnicas amplamente utilizadas para eliminar artefatos oculares, cardíacos e musculares dos sinais.

O toolkit possui capacidades de análise no domínio do tempo e no domínio tempo-frequência, utilizando transformadas como Fourier e wavelets de Morlet. Além disso, o MNE-Python implementa soluções para o problema inverso, permitindo a estimação de fontes neurais a partir das medições de sensores, utilizando métodos como *beamforming*. A biblioteca também integra ferramentas de conectividade, estatística e aprendizado de máquina, tornando-a uma solução abrangente para pesquisa em neurociência.

A estrutura de dados central do MNE-Python é organizada em três classes principais: *Raw* para dados contínuos, *Epochs* para segmentos de interesse delimitados por eventos, e *Evoked* para médias de épocas associadas a condições experimentais específicas.

3.2 Revisão da Literatura atual e Estado da Arte

Embora ferramentas consolidadas como o MNE-Python ofereçam um ecossistema robusto para o processamento clássico e estatístico de biossinais, a fronteira atual da pesquisa tem

se voltado para a aplicação de abordagens de *Deep Learning* e Modelos de Linguagem Grandes (LLMs). O estado da arte deixou de tratar os biossinais puramente como séries temporais tradicionais e passou a analisá-los com o ferramental de Processamento de Linguagem Natural (NLP), utilizando técnicas como o aprendizado autossupervisionado (SSL) e *prompt-tuning* em arquiteturas de fundação. Essa mudança de paradigma tem impulsionado avanços significativos em quatro modalidades principais de biossinais: ECG, PPG, IMU e EEG.

3.2.1 Eletrocardiograma (ECG)

A análise de ECG tem explorado fortemente a multimodalidade, combinando sinais de séries temporais com informações textuais de relatórios clínicos. O uso de LLMs, como o GPT-4, em tarefas de *Visual Question Answering* (VQA) para imagens de ECG de 12 derivações tem demonstrado precisão diagnóstica que se aproxima ou supera a de médicos especialistas na avaliação de casos de menor complexidade. Modelos omo o CKEPE utilizam LLMs para consultar bases de conhecimento clínico externas e gerar *prompts* estruturados, aprimorando substancialmente a classificação *zero-shot* e mitigando alucinações da rede. Adicionalmente, arquiteturas como o METS integram codificadores de ECG (ex., ResNet-18) e de texto (ex., ClinicalBert) em um espaço dimensional compartilhado para otimizar o diagnóstico a partir de dados não rotulados.

3.2.2 Fotopletismograma (PPG)

Os sinais de PPG, amplamente utilizados em dispositivos vestíveis para estimativa de frequência cardíaca e detecção de estresse, apresentam o desafio da alta suscetibilidade a ruídos ambientais e variações de calibração. O estado da arte tem adaptado arquiteturas de fundação, preservando os componentes centrais do modelo GPT original, mas ajustando as camadas de *embedding* para a análise de sinais contínuos. O modelo GPT-PPG, por exemplo, foi pré-treinado com mais de 200 milhões de amostras para atingir desempenho superior na estimativa da frequência cardíaca. Outro avanço pertinente é o modelo ALPHA, que aplica LLMs refinados para extrair dados fisiológicos diretamente a partir da quantificação de ciclos em imagens de PPG.

3.2.3 Sensores Inerciais (IMU)

Para os sinais de movimento capturados por acelerômetros e giroscópios, o foco recai sobre o Reconhecimento de Ações Humanas (HAR). Modelos como o LLMTrack e o HARGPT demonstraram que LLMs podem compreender dados brutos de IMU e realizar tarefas de classificação de trajetória e ação de forma *zero-shot*, utilizando apenas *prompts* adequados e superando métodos de aprendizado de máquina tradicionais, como redes LSTM e CNNs. Além disso, sistemas baseados em LLMs estão sendo empregados para gerar descrições textuais que são posteriormente convertidas em sequências de movimentos 3D (IMU virtual), visando o aumento sintético da base de dados de treinamento.

3.2.4 Eletroencefalograma (EEG) e o Modelo LUNA

O processamento de EEG apresenta desafios inerentes devido à natureza complexa, não estacionária e com alta variabilidade interindividual das ondas cerebrais. Uma das principais linhas de pesquisa atuais envolve a decodificação direta de pensamento para texto (*EEG-to-Text*), na qual modelos pré-treinados, como o BART, são utilizados para mapear *embeddings* neurais em linguagem natural.

Apesar das inovações, o maior gargalo computacional na análise de EEG por meio de *Transformers* continua sendo a heterogeneidade topológica, que compreende a variação no número e na disposição dos eletrodos entre diferentes pacientes, além das bases de dados e a complexidade de atenção quadrática $\mathcal{O}((S \cdot C)^2)$ imposta pelo longo sequenciamento espaço-temporal. Para solucionar essa limitação, destaca-se o modelo LUNA (*Latent Unified Network Architecture*), o qual atua como um modelo fundacional autossupervisionado que utiliza um mecanismo de codificação invariante à topologia.

Em vez de processar cada eletrodo individualmente em sua malha original, o LUNA utiliza *queries* aprendidas e atenção cruzada (*cross-attention*) para projetar conjuntos arbitrários de canais de EEG em um espaço latente de tamanho fixo. Essa inovação arquitetural desacopla o custo computacional do número de eletrodos físicos utilizados na captação. Como resultado, a complexidade computacional para a atenção temporal passa a escalar de forma linear, e não quadrática, o que confere ao modelo uma redução drástica no uso de memória de GPU (até 10 vezes menor) e nas operações de ponto flutuante (redução de cerca de 300 vezes no FLOPs). Pré-treinado com mais de 21.000 horas de EEG bruto sob objetivos de reconstrução mascarada,

o LUNA atinge resultados de ponta em tarefas de classificação, como a detecção de anomalias e rejeição de artefatos, mantendo alta eficácia independentemente da configuração topológica adotada na touca do paciente.

4 RESULTADOS

5 CONCLUSÕES E TRABALHOS FUTUROS

REFERÊNCIAS