



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE TELEINFORMÁTICA
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

GABRIEL VASCONCELOS FRUET
PAULO RICARDO MENEZES SOARES

AQUISIÇÃO DE BIOSINAIS

FORTALEZA

2026

GABRIEL VASCONCELOS FRUET
PAULO RICARDO MENEZES SOARES

AQUISIÇÃO DE BIOSINAIS

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação do Centro de Tecnologia da Universidade Federal do Ceará, como requisito parcial à obtenção do grau de bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Victor Hugo
Costa de Albuquerque

FORTALEZA

2026

GABRIEL VASCONCELOS FRUET
PAULO RICARDO MENEZES SOARES

AQUISIÇÃO DE BIOSINAIS

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação do Centro de Tecnologia da Universidade Federal do Ceará, como requisito parcial à obtenção do grau de bacharel em Engenharia de Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Victor Hugo Costa de
Albuquerque (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXXX XXXXXX XXXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXXX XXXXXX XXXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXX XXXXX XXXXXXX
Universidade do Membro da Banca Quatro
(SIGLA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

“O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado.”

(Ariano Suassuna)

RESUMO

ABSTRACT

LISTA DE FIGURAS

Figura 1 – Visualização dos biossinais brutos para o sujeito 000: canais de EEG, ECG, EMG e fNIRS.	39
Figura 2 – Panorama comparativo dos sinais de EEG (canal frontal AF7) para os 16 sujeitos do dataset.	40
Figura 3 – Avaliação de qualidade (SQI) para EEG: comparação entre segmento aceito e segmento rejeitado por alta curtose (instrumental).	41
Figura 4 – Histograma de amplitudes do canal EEG-AF7 (Sujeito 000) com sobreposição de curva normal teórica.	42
Figura 5 – Visualizações de diagnóstico estatístico para EEG (Sujeito 000): (a) avaliação de normalidade via quantis e (b) dispersão e <i>outliers</i> entre os 8 canais.	43
Figura 6 – Matriz de correlação cruzada entre canais e modalidades para o Sujeito 000.	44
Figura 7 – Matriz de correlação global agregada para todos os sujeitos do dataset.	45
Figura 8 – Distribuição do coeficiente de variação (CV) para EEG (Sujeito 000).	47
Figura 9 – Variância inter-janelas para EEG (Sujeito 000).	48
Figura 10 – Segmentação temporal com janelas de 5s e 50% de sobreposição para EEG (Sujeito 000).	49
Figura 11 – Distribuição dos atributos de EEG (boxplots) agregados sobre todos os sujeitos e janelas válidas.	53
Figura 12 – Distribuição dos atributos de ECG, incluindo os atributos de HRV no domínio do tempo e da frequência.	54
Figura 13 – Distribuição dos atributos de EMG, com ênfase nos descritores temporais e espectrais.	55
Figura 14 – Mapa de calor das correlações de Pearson entre atributos de EEG.	56
Figura 15 – Potência média por banda de frequência (delta, theta, alpha, beta, gamma) para cada sujeito.	57
Figura 16 – Razões de potência de banda EEG por fase experimental.	58
Figura 17 – Discriminabilidade de fase (ANOVA F -estatística) por atributo e modalidade.	59

Figura 18 – Mapa de calor de redundância entre atributos de EEG (correlação de Pearson).	60
Figura 19 – Diagrama de cotovelo para o EEG.	61
Figura 20 – Curva de variância acumulada para o EEG.	61
Figura 21 – Dispersão PC1 $\times$ PC2 para EEG por fase experimental.	62
Figura 22 – Mapa de cargas PCA para EEG: primeiros 5 componentes e os 15 atributos de maior carga absoluta.	62
Figura 23 – F -estatísticas ANOVA por componente principal para EEG.	63
Figura 24 – Curva RFECV para EEG: acurácia de validação cruzada por número de componentes retidos.	64
Figura 25 – Ranking de consenso para EEG: posição dos 15 melhores componentes nos métodos ANOVA, MI, L1-coeficiente e RFE.	64
Figura 26 – Curvas de densidade KDE por fase experimental para os três componentes EEG mais discriminativos (PC29, PC13, PC6).	66
Figura 27 – Balanceamento de classes por fase experimental para o EEG.	66

LISTA DE TABELAS

Tabela 1 – Validação das taxas de amostragem conforme o teorema de Nyquist . .	23
Tabela 2 – Justificativa empírica para os limiares de rejeição	26
Tabela 3 – Sumário técnico dos bio sinais adquiridos	37
Tabela 4 – Parâmetros de validação conforme o teorema de Nyquist	37
Tabela 5 – Resumo das falhas de integridade identificadas	38
Tabela 6 – Limiares de rejeição por modalidade de bio sinal	39
Tabela 7 – Sumário das taxas de rejeição por modalidade	40
Tabela 8 – Comparação entre metodologias de SQI	41
Tabela 9 – Caracterização estatística descritiva (Sujeito 000)	41
Tabela 10 – Efeitos da limpeza de sinais (Sujeito 000)	44
Tabela 11 – Sumário da segmentação temporal por modalidade	46
Tabela 12 – Métricas de estabilidade intra-janela (Sujeito 000)	47
Tabela 13 – Retenção de janelas por sujeito e modalidade	50
Tabela 14 – Resumo da matriz de atributos extraída no Estágio 6	52
Tabela 15 – Colunas adicionadas pela engenharia de atributos por modalidade . . .	58
Tabela 16 – Resultados da PCA por modalidade	59
Tabela 17 – Resultados da seleção de atributos por modalidade	63
Tabela 18 – Resultados da validação estatística final por modalidade	65

LISTA DE SÍMBOLOS

A_e	Área efetiva da antena
B	Largura de faixa em que o ruído é medido em Hertz
d	Distância em metros
E	Campo elétrico
FA	Fator da antena
Gr	Ganho de recepção
h	Altura efetiva ou comprimento efetivo de uma antena
I	Corrente elétrica
k	Constante de Boltzmann's
K	Eficiência de irradiação
M	Variação do patamar de ruído em função da RBW
N	Condutor de neutro
NF	Figura de ruído
N_i	Potência do ruído na entrada
N_o	Potência do ruído na saída
P	Potência
R	Resistência
S_i	Potência do sinal na entrada
S_o	Potência do sinal na saída
t	Tempo
V	Tensão
Z_L	Impedância da antena
Z_o	Impedância de referência (50Ω)
λ	Comprimento de onda
Γ	Coefficiente de reflexão

SUMÁRIO

1	INTRODUÇÃO	18
1.1	Objetivos	18
1.2	Organização do Trabalho	19
2	FUNDAMENTAÇÃO TEÓRICA	20
2.1	Biossinais	20
2.2	Teorema de Amostragem de Nyquist	20
2.3	Ferramentas de Processamento	21
3	METODOLOGIA	22
3.1	Caracterização do Dataset	22
3.2	Protocolo Experimental	22
3.3	Validação do Teorema de Nyquist	22
3.4	Ambiente de Desenvolvimento	23
3.5	Avaliação de Qualidade do Sinal (SQI)	23
3.5.1	<i>Segmentação de Janelas</i>	23
3.5.2	<i>Métricas de Qualidade Estatística</i>	23
3.5.3	<i>Análise no Domínio da Frequência</i>	24
3.5.4	<i>Classificação e Lógica de Rejeição</i>	24
3.5.5	<i>Calibração Empírica dos Limiares</i>	24
3.6	Análise Estatística Descritiva e Testes de Hipótese	25
3.6.1	<i>Estatística Descritiva e Momentos de Alta Ordem</i>	25
3.6.2	<i>Testes de Normalidade e Homocedasticidade</i>	25
3.6.3	<i>Análise de Correlação Inter-Modalidade</i>	26
3.7	Limpeza e Correção de Sinais	26
3.7.1	<i>Filtragem no Domínio da Frequência</i>	26
3.7.2	<i>Interpolação de Lacunas</i>	27
3.7.3	<i>Winsorização</i>	27
3.7.4	<i>Rejeição por Z-Score</i>	27
3.8	Segmentação Temporal (Janelamento)	27
3.8.1	<i>Definição de Janelas de Tempo</i>	27
3.8.2	<i>Janelas com Sobreposição</i>	28

3.8.3	<i>Cr�terios de Estabilidade Intra-Janela</i>	28
3.8.4	<i>Propaga��o de Rejei��o via SQI</i>	28
3.8.5	<i>M�tricas de An�lise Inter-Janelas</i>	28
3.8.6	<i>Cache de Segmentos</i>	29
3.9	<i>Extra��o de Atributos</i>	29
3.9.1	<i>Atributos no Dom�nio do Tempo</i>	29
3.9.2	<i>Atributos no Dom�nio da Freq��ncia</i>	30
3.9.3	<i>Atributos de Variabilidade Card�aca (ECG)</i>	30
3.10	<i>Engenharia de Atributos</i>	30
3.10.1	<i>Atribui��o de Fase Experimental</i>	30
3.10.2	<i>Raz�es de Pot�ncia de Banda (EEG)</i>	31
3.10.3	<i>Normaliza��o pela Linha de Base</i>	31
3.10.4	<i>Atributos Delta (Δ, Δ^2)</i>	31
3.10.5	<i>Agrega��es Temporais</i>	31
3.10.6	<i>An�lise de Redund�ncia e Discriminabilidade</i>	32
3.11	<i>Sele��o de Atributos</i>	32
3.11.1	<i>M�todos de Filtro</i>	32
3.11.2	<i>M�todo Envolt�rio — RFECV</i>	32
3.11.3	<i>M�todo Embutido — SVC-L1</i>	33
3.11.4	<i>Ranking de Consenso</i>	33
3.12	<i>Redu��o de Dimensionalidade</i>	33
3.12.1	<i>Motiva��o</i>	33
3.12.2	<i>Pr�-processamento</i>	34
3.12.3	<i>An�lise de Componentes Principais</i>	34
3.12.4	<i>Visualiza��es</i>	34
3.13	<i>Valida��o Estat�stica Final</i>	34
3.13.1	<i>Verifica��o de Multicolinearidade (VIF)</i>	35
3.13.2	<i>An�lise de Separabilidade de Fase</i>	35
3.13.3	<i>Balanceamento de Classes</i>	35
3.13.4	<i>Montagem do Dataset Final</i>	35
3.14	<i>Estrutura do Pipeline de Processamento</i>	36
4	<i>AN�LISE DOS RESULTADOS</i>	37

4.1	Aquisição e Carga de Dados	37
4.2	Validação de Nyquist	37
4.3	Identificação de Falhas de Aquisição	37
4.4	Inspeção Visual dos Registros Brutos	38
4.5	Avaliação de Qualidade do Sinal	38
4.5.1	<i>Calibração de Limiares por Modalidade</i>	38
4.5.2	<i>Análise Quantitativa de Rejeição</i>	39
4.5.3	<i>Inspeção de Artefatos Identificados</i>	40
4.5.4	<i>Comparação com Abordagens da Literatura</i>	40
4.6	Análise Estatística dos Sinais	41
4.6.1	<i>Resultados dos Testes de Normalidade</i>	42
4.6.2	<i>Testes de Homocedasticidade</i>	42
4.6.3	<i>Correlação entre Canais e Modalidades</i>	43
4.7	Limpeza e Correção de Sinais	43
4.7.1	<i>Redução de Variância e Efeito de Cohen</i>	45
4.7.2	<i>Normalização de Curtose</i>	45
4.7.3	<i>Interpolação de Lacunas</i>	46
4.7.4	<i>Manutenção de fNIRS</i>	46
4.8	Segmentação Temporal dos Sinais	46
4.8.1	<i>Análise de Estabilidade Intra-Janela</i>	47
4.8.2	<i>Variância Inter-Janelas</i>	48
4.8.3	<i>Propagação de Máscaras de Qualidade</i>	48
4.8.4	<i>Visualização das Janelas</i>	48
4.8.5	<i>Cache de Segmentos Gerados</i>	49
4.8.6	<i>Análise Inter-Sujeitos e Padrões Observados</i>	49
4.9	Discussão dos Achados	51
4.10	Extração de Atributos	52
4.10.1	<i>Matriz de Atributos Gerada</i>	52
4.10.2	<i>Atributos Temporais e Espectrais</i>	52
4.10.3	<i>Correlação entre Atributos</i>	55
4.10.4	<i>Potência por Bandas de EEG</i>	55
4.10.5	<i>Variabilidade da Frequência Cardíaca (ECG)</i>	56

4.10.6	<i>Atributos de EMG</i>	57
4.11	Engenharia de Atributos	57
4.11.1	<i>Matriz Enriquecida</i>	57
4.11.2	<i>Razões de Potência de Banda EEG</i>	58
4.11.3	<i>Discriminabilidade entre Fases</i>	58
4.11.4	<i>Análise de Redundância</i>	59
4.12	Redução de Dimensionalidade	59
4.12.1	<i>EEG</i>	59
4.12.2	<i>ECG e EMG</i>	61
4.13	Seleção de Atributos	62
4.13.1	<i>EEG</i>	63
4.13.2	<i>ECG e EMG</i>	63
4.14	Validação Estatística Final	65
4.14.1	<i>Multicolinearidade</i>	65
4.14.2	<i>Separabilidade de Fase</i>	65
4.14.3	<i>Balanceamento de Classes</i>	65
4.14.4	<i>Dataset Final</i>	66
5	CONCLUSÕES E TRABALHOS FUTUROS	68
	REFERÊNCIAS	69

1 INTRODUÇÃO

Biossinais são manifestações físicas, químicas ou elétricas decorrentes de processos fisiológicos do corpo humano. Tais sinais carregam informações fundamentais sobre o estado funcional de órgãos e sistemas, possuindo aplicações consolidadas em diagnóstico clínico, monitoramento de pacientes, interfaces cérebro-máquina e reconhecimento de estados emocionais.

Este trabalho descreve o desenvolvimento de um pipeline para o processamento de biossinais multimodais, estruturado desde a aquisição dos dados brutos até a consolidação de um conjunto de dados validado para técnicas de reconhecimento de padrões. O fluxo de processamento é dividido em dez etapas sequenciais: aquisição, avaliação de qualidade via índices de qualidade do sinal (SQI), análise estatística exploratória, limpeza e correção de artefatos, segmentação temporal, extração de atributos, engenharia de atributos, redução de dimensionalidade, seleção de variáveis e, por fim, validação estatística do conjunto de dados resultante.

Para o desenvolvimento do pipeline, utilizou-se o *IEEE Multimodal Emotion Recognition Dataset*, que contém registros de 16 sujeitos experimentais. O conjunto de dados abrange quatro modalidades distintas: eletroencefalografia (EEG) com 8 canais, eletrocardiografia (ECG), eletromiografia (EMG) e espectroscopia de infravermelho próximo funcional (fNIRS). Cada registro possui entre 60 e 260 segundos de duração, variando conforme a modalidade e o participante.

Este relatório detalha os resultados obtidos no primeiro estágio do pipeline, concentrando-se nos procedimentos de aquisição, carga de dados e validação inicial da integridade dos biossinais.

1.1 Objetivos

O objetivo central deste trabalho é a implementação de um fluxo de processamento reprodutível para biossinais multimodais, visando a geração de uma base de dados robusta para modelos de aprendizado de máquina. Especificamente, busca-se validar a integridade física dos sinais, verificar a conformidade com o teorema de amostragem de Nyquist para todas as modalidades, identificar falhas de aquisição e estabelecer o rigor metodológico necessário para as etapas subsequentes do projeto.

1.2 Organização do Trabalho

O presente documento está estruturado em cinco capítulos. O Capítulo 2 aborda os conceitos teóricos sobre os biossinais analisados e as técnicas de processamento. O Capítulo 3 descreve os métodos aplicados, incluindo a caracterização do dataset e do ambiente computacional. O Capítulo 4 apresenta a análise dos dados adquiridos e as validações realizadas. Por fim, o Capítulo 5 expõe as conclusões deste estágio e as propostas para o desenvolvimento das próximas fases do pipeline.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Biossinais

Biossinais são representações temporais de fenômenos fisiológicos que, por meio de transdutores adequados, são convertidos em sinais elétricos. Cada modalidade biológica apresenta propriedades distintivas quanto à frequência, amplitude e mecanismos de geração.

O eletroencefalograma, referido como EEG, registra a atividade elétrica do córtex cerebral por meio de eletrodos extracranianos. Os sinais EEG são segmentados em bandas de frequência: delta (0,5–4 Hz), theta (4–8 Hz), alpha (8–13 Hz), beta (13–30 Hz) e gamma (>30 Hz). A amplitude desses sinais oscila tipicamente entre 5 e 100 μV , dependendo do estado cortical.

O eletrocardiograma, ou ECG, monitora a despolarização e repolarização cardíaca, manifestando-se como ondas características designadas P, Q, R, S e T. As frequências de interesse para análise cardíaca situam-se primordialmente entre 0,5 e 40 Hz, com picos de amplitude em torno de 1 mV.

O eletromiograma de superfície, abreviado como EMG, capta o somatório dos potenciais de ação das unidades motoras durante a contração muscular esquelética. Sua banda de frequência predominante estende-se de 20 a 250 Hz, com amplitudes variando de 0,1 a 5 mV.

A espectroscopia de infravermelho próximo funcional, designada fNIRS, é uma técnica óptica que utiliza comprimentos de onda entre 650 e 950 nm para quantificar flutuações nas concentrações de oxiemoglobina e desoxiemoglobina. Tais variações hemodinâmicas, processadas pela lei de Beer-Lambert modificada, ocorrem em frequências inferiores a 0,5 Hz.

2.2 Teorema de Amostragem de Nyquist

O teorema de Nyquist-Shannon postula que um sinal contínuo com banda limitada pode ser perfeitamente reconstruído a partir de suas amostras discretas caso a taxa de amostragem seja superior ao dobro da frequência máxima contida no sinal original. Matematicamente, $f_s > 2 \cdot f_{max}$, onde f_s representa a frequência de amostragem e f_{max}

a frequência de corte do sinal. O cumprimento desse critério é essencial para mitigar o fenômeno de aliasing e preservar a fidelidade espectral da aquisição.

2.3 Ferramentas de Processamento

A biblioteca MNE-Python é uma ferramenta de código aberto para a análise e visualização de dados neurofisiológicos multimodais. O toolkit oferece suporte para EEG, MEG, sEEG, ECoG e fNIRS, organizando os dados em estruturas de classe *Raw* para sinais contínuos, *Epochs* para janelas baseadas em eventos e *Evoked* para processamento estatístico de médias.

Os índices de qualidade do sinal, genericamente referidos como SQI, são ferramentas diagnósticas que avaliam a integridade dos biossinais por meio de parâmetros estatísticos e espectrais. Métricas recorrentes incluem a razão sinal-ruído, curtose, assimetria e entropia espectral, permitindo a exclusão automatizada de registros corrompidos por artefatos instrumentais ou fisiológicos.

3 METODOLOGIA

3.1 Caracterização do Dataset

Utilizou-se o *Dataset of Multi-Modal Physiological Signals* (disponível em IEEE DataPort) (NASER *et al.*, 2023), contendo registros de 16 participantes expostos a estímulos visuais indutores de emoções. O dataset compreende quatro modalidades de biossinais: EEG (Emotiv EPOC+, 8 canais), ECG, EMG e fNIRS. Os sinais foram sincronizados e armazenados com marcadores temporais indicando os momentos de linha de base e estimulação.

Os 8 canais de EEG foram posicionados em AF7, AF8, F3, F4, PO7, PO8, PO3 e PO4, operando a uma frequência de amostragem de 512 Hz. As modalidades de ECG e EMG foram registradas com canais únicos a 250 Hz. O sistema de fNIRS registrou as concentrações de oxiemoglobina e desoxiemoglobina em dois canais a 16 Hz.

3.2 Protocolo Experimental

O protocolo de aquisição está subdividido em duas etapas principais. A etapa inicial compreende uma linha de base com duração de 30 segundos, durante a qual o participante permanece em estado de repouso para o estabelecimento dos parâmetros fisiológicos basais. A segunda etapa consiste em um estímulo emocional controlado com duração de 30 segundos, totalizando períodos de registro variáveis de aproximadamente 60 a 260 segundos por participante, dependendo da modalidade e do sujeito.

3.3 Validação do Teorema de Nyquist

As frequências de amostragem configuradas foram validadas conforme o teorema de amostragem de Nyquist. Para o sinal de EEG, com frequência máxima de 50 Hz e amostragem de 512 Hz, obteve-se uma razão de 5,12. No sinal de ECG, com frequência máxima de 40 Hz amostrado a 250 Hz, a razão calculada foi de 3,13. No EMG, considerando frequência de corte de 100 Hz e amostragem de 250 Hz, a razão foi de 1,25. Por fim, para o fNIRS, com frequência máxima de 2 Hz e amostragem de 16 Hz, a razão obtida foi de 4,00. Todos os parâmetros atendem plenamente ao critério de Nyquist, conforme detalhado na Tabela 1.

Tabela 1 – Validação das taxas de amostragem conforme o teorema de Nyquist

Modalidade	f_s (Hz)	f_{max} (Hz)	$f_s/2f_{max}$	Conforme
EEG	512	50	5,12	Sim
ECG	250	40	3,13	Sim
EMG	250	100	1,25	Sim
fNIRS	16	2	4,00	Sim

3.4 Ambiente de Desenvolvimento

O fluxo de processamento foi desenvolvido em linguagem Python, versão 3.13, integrando a biblioteca MNE-Python para o pré-processamento de biossinais. As bibliotecas NumPy e Pandas foram empregadas para manipulação de tensores e matrizes de dados, enquanto Matplotlib e SciPy foram utilizadas para visualização e processamento digital de sinais. O gerenciamento de dependências foi executado por meio da ferramenta uv e do arquivo de configuração pyproject.toml, assegurando a reprodutibilidade do ambiente computacional.

3.5 Avaliação de Qualidade do Sinal (SQI)

No segundo estágio do pipeline, implementou-se um sistema de avaliação automática de qualidade (*Signal Quality Index* — SQI) para assegurar a validade fisiológica dos dados. O processo fundamenta-se na segmentação temporal e na extração de descritores estatísticos e espectrais.

3.5.1 Segmentação de Janelas

Os sinais brutos foram particionados em janelas de tempo fixas de $T = 5$ segundos. Esta duração foi selecionada para capturar características quase-estacionárias dos biossinais (especialmente EEG e ECG) enquanto permite uma resolução temporal adequada para a detecção de transientes de ruído e artefatos de movimento.

3.5.2 Métricas de Qualidade Estatística

Para cada janela w_i , calcularam-se métricas de momentos centrais:

- **Curtose (K):** Utilizada para detectar *outliers* e picos de tensão (*spikes*) anormais, onde valores elevados indicam presença de ruído impulsivo ou transientes

instrumentais.

- **Assimetria (S):** Medida da falta de simetria na distribuição de amplitudes, sensível a desvios de linha de base e saturação assimétrica (*clipping*).
- **Amplitude IQR:** A amplitude interquartil foi empregada como descritor de dispersão robusto para identificar variações bruscas de magnitude associadas a movimentos do sujeito.

3.5.3 *Análise no Domínio da Frequência*

A integridade espectral foi avaliada por meio de:

- **Relação Sinal-Ruído (SNR):** Estimada através da densidade espectral de potência (PSD) calculada pelo método de Welch. O SNR em dB foi definido pela razão entre a potência na banda de interesse fisiológico e a potência do ruído de fundo em bandas adjacentes.
- **Entropia Espectral (H_{spec}):** Calculada como a entropia de Shannon normalizada do espectro de potências. Sinais biológicos íntegros apresentam complexidade espectral característica, enquanto sinais contaminados por ruído branco ou interferência senoidal pura (60 Hz) apresentam desvios significativos nesta métrica.

3.5.4 *Classificação e Lógica de Rejeição*

A decisão de aceitação de um segmento baseou-se em um conjunto de regras heurísticas e limiares (θ) específicos por modalidade m :

$$f(w_i) = \begin{cases} \text{Aceito,} & \text{se } SNR > \theta_{SNR} \wedge K < \theta_K \wedge H > \theta_H \\ \text{Rejeitado,} & \text{caso contrário} \end{cases} \quad (3.1)$$

Adicionalmente, janelas com variância próxima a zero ($\sigma^2 < \epsilon$) foram automaticamente rotuladas como *Loose Electrode* (Eletrodo Solto), enquanto variações de amplitude superiores a 10 vezes o desvio padrão global foram classificadas como *Movement Artifact*.

3.5.5 *Calibração Empírica dos Limiares*

Os limiares de rejeição (θ) foram estabelecidos por meio de uma abordagem empírica combinada com referências da literatura. O procedimento consistiu em:

1. **Análise de Distribuição:** Calculou-se a distribuição estatística das métricas (SNR, curtose, entropia) para todos os segmentos de todos os sujeitos, identificando valores extremos e suas causas conhecidas.
2. **Calibração por Modalidade:** Os limiares foram ajustados para cada modalidade considerando:
 - EEG: Sensibilidade alta a piscadas oculares e artefatos de movimento (curtose elevada esperada).
 - ECG: Presença de *spikes* R (curtose muito alta esperada).
 - EMG: Atividade muscular descontínua (entropia variável).
 - fNIRS: Relação sinal-ruído intrinsecamente baixa.
3. **Validação Visual:** Os limiares foram validados por inspeção visual de segmentos aceitos e rejeitados, conforme exemplificado na Figura 3.

3.6 Análise Estatística Descritiva e Testes de Hipótese

No terceiro estágio, realizou-se uma caracterização estatística exaustiva dos biossinais para compreender as distribuições de amplitude e as dependências entre canais.

3.6.1 Estatística Descritiva e Momentos de Alta Ordem

Para cada canal de cada modalidade, computaram-se:

- **Medidas de Tendência Central e Dispersão:** Média, mediana, variância, desvio padrão e intervalo interquartil (IQR).
- **Momentos de Alta Ordem:** Curtose e Assimetria (*Skewness*), essenciais para caracterizar o desvio da normalidade e a presença de caudas pesadas no sinal.

3.6.2 Testes de Normalidade e Homocedasticidade

A natureza estocástica dos sinais foi avaliada por meio de:

- **Teste de Shapiro-Wilk (SHAPIRO; WILK, 1965):** Aplicado como teste primário de normalidade (limitado a 5000 amostras).
- **Teste de Kolmogorov-Smirnov (K-S):** Utilizado como teste de aderência contra uma distribuição normal teórica.
- **Teste de Levene (LEVENE, 1960):** Empregado para avaliar a homocedasticidade

(igualdade de variâncias) entre os canais de uma mesma modalidade, sendo robusto a desvios de normalidade.

3.6.3 *Análise de Correlação Inter-Modalidade*

Calculou-se a matriz de correlação de Pearson entre todos os canais sincronizados. Esta análise permite identificar redundâncias entre canais de EEG e acoplamentos fisiológicos entre diferentes modalidades (ex: influência da frequência cardíaca no sinal fNIRS).

A Tabela 2 sintetiza a fundamentação dos limiares estabelecidos.

Tabela 2 – Justificativa empírica para os limiares de rejeição

Modalidade	Limiar	Fundamentação
EEG	SNR mín. $-5,0$ dB	Inferior ao ruído instrumental típico
EEG	Curtose máx. $50,0$	Captura piscadas sem rejeitar fisiológico
ECG	Curtose máx. $100,0$	Accomoda picos R pronunciados
EMG	Entropia mín. $0,20$	Detecta bursts musculares íntegros
fNIRS	SNR mín. $-50,0$ dB	Ruído fotônico intrínseco

3.7 Limpeza e Correção de Sinais

No quarto estágio do pipeline, implementou-se um conjunto de técnicas de pré-processamento para correção de artefatos e normalização estatística dos sinais bioassinais.

3.7.1 *Filtragem no Domínio da Frequência*

A remoção de interferência elétrica foi realizada por meio de dois filtros digitais complementares:

- **Filtro Notch (50 Hz):** Elimina a interferência da rede elétrica brasileira (60 Hz para EUA, 50 Hz para Europa).
- **Filtro Passa-Banda (Band-Pass):** Parâmetros específicos por modalidade para

preservar a banda fisiológica de interesse:

- EEG: 0,5 – 50 Hz (captura bandas delta a beta)
- ECG: 0,5 – 50 Hz (preserva complexo QRS e ondas T)
- EMG: 20 – 250 Hz (banda clássica de EMG de superfície)
- fNIRS: 0,01 – 0,1 Hz (apenas variações hemodinâmicas lentas)

3.7.2 *Interpolação de Lacunas*

Gaps temporais (ausências de sinal) foram identificados e preenchidos por interpolação linear para extensão máxima de 1 segundo. Lacunas maiores foram preservadas como segmentos inválidos para posterior rejeição.

3.7.3 *Winsorização*

A normalização de *outliers* foi aplicada por Winsorização no percentil 5º e 95º, substituindo valores extremos pelos limiares correspondentes em vez de descartá-los. Esta abordagem preserva o número de amostras enquanto reduz a influência de artefatos impulsivos.

3.7.4 *Rejeição por Z-Score*

Após a Winsorização, outliers residuais foram identificados por z-scores superiores a 3,0 em valor absoluto, correspondendo a aproximadamente 0,27% de rejeição sob distribuição normal teórica.

3.8 Segmentação Temporal (Janelamento)

No quinto estágio do pipeline, implementou-se a segmentação dos sinais em janelas temporais de tamanho fixo, propagando as informações de qualidade (SQI) obtidas no Estágio 2 para garantir a integridade dos segmentos.

3.8.1 *Definição de Janelas de Tempo*

Os sinais limpos foram particionados em janelas de tempo fixas com duração de $T = 5$ segundos, selecionadas para capturar características fisiológicas estáveis enquanto

mantêm resolução temporal adequada. A escolha de 5 segundos justifica-se por:

- EEG: Captura pelo menos 2–3 ciclos completos de ondas alpha (8–12 Hz).
- ECG: Captura aproximadamente 5–6 batimentos cardíacos normais.
- EMG: Captura padrões de ativação muscular representativos.
- fNIRS: Permite análise de variações hemodinâmicas (banda 0,01–0,1 Hz).

3.8.2 Janelas com Sobreposição

Para maximizar a utilização dos dados, implementou-se suporte a janelas sobrepostas (*overlapping windows*) com fração de sobreposição configurável. A taxa de sobreposição o define a proporção do deslocamento entre janelas consecutivas:

$$\text{stride} = T \times (1 - o) \quad (3.2)$$

3.8.3 Critérios de Estabilidade Intra-Janela

Cada segmento foi submetido a testes de estacionariedade e homogeneidade para garantir a validade fisiológica:

- **Coefficiente de Variação (CV):** Garantiu-se que o CV da janela seja inferior a 30%, indicando estabilidade de amplitude.
- **Teste de Dickey-Fuller Aumentado (ADF):** Avaliou-se a estacionariedade estatística do segmento, rejeitando janelas não-estacionárias.

3.8.4 Propagação de Rejeição via SQI

As informações de qualidade calculadas no Estágio 2 foram propagadas para o janelamento:

- Segmentos rejeitados no SQI (Loose Electrode, Movement Artifact, SNR baixo) foram marcados como inválidos.
- Segmentos parcialmente válidos tiveram suas máscaras de rejeição armazenadas para exclusão em análises subsequentes.

3.8.5 Métricas de Análise Inter-Janelas

Para caracterizar a variabilidade entre segmentos de um mesmo sujeito, calculou-se:

- **Variância Inter-Janelas:** Medida da dispersão de descritores estatísticos entre segmentos consecutivos.
- **Correlação Cruzada:** Análise de similaridade morfológica entre janelas adjacentes.

3.8.6 Cache de Segmentos

Os segmentos válidos foram armazenados em arquivos `.npz` (NumPy compressed archive) para uso eficiente nos estágios subsequentes de extração de atributos. Cada arquivo contém:

- Sinais de todas as modalidades para o sujeito.
- Vetores de máscara indicando amostras válidas/inválidas.
- Metadados: timestamps, durações, limiares utilizados.

3.9 Extração de Atributos

No sexto estágio do pipeline, descritores quantitativos são extraídos de cada janela temporal gerada no Estágio 5, construindo a matriz de atributos para aprendizado de máquina. A modalidade fNIRS foi definitivamente excluída neste estágio, confirmando o resultado do Estágio 5 em que menos de 2,5% das janelas foram retidas.

3.9.1 Atributos no Domínio do Tempo

Para todas as modalidades ativas (EEG, ECG e EMG), os seguintes descritores temporais são calculados por canal e por janela:

- **RMS** (*Root Mean Square*): $\text{RMS} = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$ — amplitude efetiva do sinal.
- **MAV** (*Mean Absolute Value*): $\text{MAV} = \frac{1}{N} \sum_{i=1}^N |x_i|$ — indicador de ativação.
- **Variância:** $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$.
- **ZCR** (*Zero Crossing Rate*): taxa de cruzamentos por zero, sensível à frequência dominante.
- **Parâmetros de Hjorth:** Atividade (σ^2), Mobilidade ($\sqrt{\sigma_{dx}^2/\sigma_x^2}$) e Complexidade (razão de mobilidades de primeira e segunda derivadas), que caracterizam espalhamento espectral sem transformada de Fourier.
- **Assimetria e Curtose:** momentos estatísticos de terceira e quarta ordem, respectivamente.

3.9.2 Atributos no Domínio da Frequência

A estimativa da Densidade Espectral de Potência (DEP) é realizada pelo método de Welch, com janela de Hann e $nperseg = \min(256, N)$ amostras. Os atributos extraídos são:

- **Potência Total:** integral da DEP pela regra trapezoidal.
- **Frequência Média e Mediana:** média ponderada pela potência e frequência onde a potência acumulada atinge 50%.
- **Entropia Espectral:** $H = -\sum p_i \log_2 p_i$, onde p_i é a DEP normalizada.
- **Potência por Bandas (EEG):** delta (0,5–4 Hz), theta (4–8 Hz), alpha (8–13 Hz), beta (13–30 Hz) e gamma (30–50 Hz).

3.9.3 Atributos de Variabilidade Cardíaca (ECG)

Para o ECG, atributos adicionais de Variabilidade da Frequência Cardíaca (VFC) são extraídos a partir da detecção de picos R por *threshold* adaptativo com `scipy.signal.find_peaks`:

- **Domínio do tempo (HRV):** $\overline{RR}$, SDNN (desvio padrão dos intervalos RR), RMSSD (raiz quadrada da média dos quadrados das diferenças sucessivas) e pNN50 (proporção de diferenças sucessivas maiores que 50 ms).
- **Domínio da frequência (HRV):** potência nas bandas LF (0,04–0,15 Hz) e HF (0,15–0,40 Hz), e razão LF/HF, estimadas sobre o tacograma RR reamostrado a 4 Hz.

3.10 Engenharia de Atributos

O sétimo estágio aplica transformações sobre a matriz de atributos gerada no Estágio 6, enriquecendo-a com novos descritores derivados e normalizações contextuais. O protocolo experimental (linha de base 30 s $\rightarrow$ estimulação 30 s $\rightarrow$ recuperação) é utilizado para atribuir rótulos de fase a cada janela temporal.

3.10.1 Atribuição de Fase Experimental

Cada janela recebe um rótulo de fase baseado em seu instante de início (t_{start}):

- **Linha de base (*baseline*):** $t_{\text{start}} < 30$ s
- **Estimulação (*stimulation*):** $30 \leq t_{\text{start}} < 60$ s
- **Recuperação (*recovery*):** $t_{\text{start}} \geq 60$ s

3.10.2 Razões de Potência de Banda (EEG)

Cinco razões espectrais são derivadas a partir das potências de banda extraídas no Estágio 6:

- **alpha/beta:** indicador de relaxamento vs. vigilância.
- **theta/alpha:** proxy de carga cognitiva.
- **Índice de Engajamento:** $\beta/(\alpha + \theta)$ — ativação cortical.
- **delta/beta:** contraste sono vs. atividade.
- **theta/beta:** proxy de ansiedade e estresse.

3.10.3 Normalização pela Linha de Base

Para cada tripla (sujeito, canal, atributo), computa-se a média μ_b e o desvio padrão σ_b das janelas de linha de base. Cada janela é então normalizada em z-score relativo à linha de base:

$$x_{\text{norm}} = \frac{x - \mu_b}{\sigma_b + \varepsilon} \quad (3.3)$$

3.10.4 Atributos Delta (Δ , Δ^2)

Derivadas temporais discretas de primeira e segunda ordem são calculadas para cinco atributos selecionados por modalidade, capturando a dinâmica de evolução do sinal ao longo das janelas consecutivas:

$$\Delta f_i = f_{i+1} - f_i, \quad \Delta^2 f_i = \Delta f_{i+1} - \Delta f_i \quad (3.4)$$

3.10.5 Agregações Temporais

Para cada combinação (sujeito, canal, fase), calculam-se média, desvio padrão, mínimo e máximo de todos os atributos, produzindo um CSV agregado por sujeito para uso nos estágios de redução de dimensionalidade e seleção.

3.10.6 *Análise de Redundância e Discriminabilidade*

A redundância é avaliada pelo coeficiente de correlação de Pearson entre pares de atributos: pares com $|r| \geq 0,95$ são sinalizados como altamente redundantes. A discriminabilidade entre fases é estimada pelo teste ANOVA unidirecional (F -estatística) aplicado a cada atributo, identificando quais descritores melhor separam as três condições experimentais.

3.11 Seleção de Atributos

O nono estágio aplica três famílias complementares de seleção de atributos sobre os componentes principais produzidos pelo Estágio 8, com o objetivo de identificar as representações mais informativas para discriminar as fases experimentais (linha de base, estimulação e recuperação).

3.11.1 *Métodos de Filtro*

Os métodos de filtro avaliam cada componente independentemente da função de classificação, com base em estatísticas de associação com a variável de resposta (fase experimental):

- **ANOVA unidirecional** ($f_classif$): computa a F -estatística para cada componente principal, testando a hipótese nula de que as médias são iguais nas três fases. O efeito é quantificado pelo coeficiente f^2 de Cohen:

$$f^2 = \frac{F \cdot (k - 1)}{n - k} \quad (3.5)$$

onde $k = 3$ fases e n é o número de observações.

- **Correção de Bonferroni** (SEL-005): os p -valores são multiplicados pelo número de testes simultâneos ($p_{\text{corr}} = \min(p \cdot m, 1)$) para controlar o erro tipo I familiar.
- **Informação Mútua** ($mutual_info_classif$): estima a dependência não linear entre cada componente e a fase, complementando a F -estatística para relações não-lineares.

3.11.2 *Método Envoltório — RFECV*

O método envoltório implementa Eliminação Recursiva de Atributos com Validação Cruzada (*Recursive Feature Elimination with Cross-Validation* — RFECV)

usando um SVC linear como estimador base. O RFECV determina iterativamente o número ótimo de componentes k^* que maximiza a acurácia em validação cruzada estratificada de $K = 5$ partições:

$$k^* = \arg \max_k \overline{\text{acc}}_{\text{CV}}(k) \quad (3.6)$$

3.11.3 Método Embutido — SVC-L1

O método embutido treina um SVC linear com regularização L1 ($C = 0,1$), que produz coeficientes esparsos. Componentes com coeficiente máximo absoluto $\max_c |w_{ck}| > 0$ são considerados relevantes para pelo menos uma das três classes.

3.11.4 Ranking de Consenso

Para cada componente, calcula-se a posição no ranking de cada método (ANOVA, MI e L1-coeficiente), e o *rank* de consenso é a média aritmética das três posições. Os k_{RFE}^* componentes de menor *rank* de consenso compõem o subconjunto final de atributos selecionados.

3.12 Redução de Dimensionalidade

O oitavo estágio do pipeline aplica Análise de Componentes Principais (*Principal Component Analysis* — PCA) à matriz de atributos agregada pelo Estágio 7, com o objetivo de mitigar a maldição da dimensionalidade e remover redundâncias lineares remanescentes antes da seleção de variáveis.

3.12.1 Motivação

A relação entre o número de observações (n) e o número de atributos (p) é crítica para a generalização de modelos de aprendizado de máquina. Após o Estágio 7, a matriz de EEG apresenta $n = 375$ observações e $p = 224$ colunas, enquanto ECG ($n = 41$, $p = 200$) e EMG ($n = 37$, $p = 144$) estão em regime subdeterminado ($n < p$). A PCA projeta os dados em um subespaço de menor dimensão preservando a máxima variância.

3.12.2 Pré-processamento

Antes da decomposição, aplica-se o seguinte procedimento por modalidade:

1. **Remoção de colunas NaN:** colunas com mais de 50% de valores ausentes são descartadas. No ECG, as 24 colunas derivadas de *lf_power*, *hf_power* e *lf_hf_ratio* são eliminadas nesta etapa, pois são todas nulas devido à limitação de resolução espectral das janelas de 5 s.
2. **Imputação:** valores ausentes remanescentes são preenchidos pela mediana da coluna.
3. **Padronização:** *StandardScaler* ($\mu = 0$, $\sigma = 1$) é aplicado a todos os atributos numéricos para garantir que a PCA não seja dominada por escala.

3.12.3 Análise de Componentes Principais

A PCA é ajustada com $k = \min(n, p)$ componentes. O critério de seleção do número de componentes a reter baseia-se na variância acumulada explicada:

$$k^* = \min \left\{ k : \sum_{i=1}^k \lambda_i / \sum_{j=1}^p \lambda_j \geq \tau \right\} \quad (3.7)$$

onde λ_i são os autovalores ordenados de forma decrescente e $\tau \in \{0,90; 0,95\}$ são os limiares de variância considerados. Os dados transformados com k_{95}^* componentes são salvos para uso no Estágio 9.

3.12.4 Visualizações

Para cada modalidade são gerados quatro gráficos: (i) diagrama de cotovelo (*scree plot*) com as variâncias individuais dos primeiros 20 componentes; (ii) curva de variância acumulada com marcadores nos limiares de 90% e 95%; (iii) dispersão PC1 $\times$ PC2 colorida por fase experimental; (iv) mapa de calor das cargas dos primeiros 5 componentes sobre os 15 atributos de maior carga absoluta.

3.13 Validação Estatística Final

O décimo estágio verifica a prontidão do conjunto de dados para o aprendizado de máquina mediante quatro critérios quantitativos, e consolida os componentes selecionados em um único arquivo cruzado entre modalidades.

3.13.1 Verificação de Multicolinearidade (VIF)

O Fator de Inflação da Variância (*Variance Inflation Factor* — VIF) mede a redundância linear entre atributos. Para o atributo j :

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (3.8)$$

onde R_j^2 é o coeficiente de determinação da regressão de X_j sobre os demais atributos. Como os componentes principais são ortogonais por construção, espera-se $\text{VIF} = 1,0$ para todos os componentes. Valores acima de 5 são sinalizados como moderados e acima de 10 como severos.

3.13.2 Análise de Separabilidade de Fase

A separabilidade entre as três fases experimentais é avaliada por dois indicadores complementares:

1. **η^2 de Cohen** por componente (via ANOVA unidirecional): mede a proporção de variância explicada pela fase como variável de grupo.
2. **Traço de Pillai** (aproximação multivariada): $\text{Pillai} = \text{tr}(\mathbf{S}_B \mathbf{S}_T^{-1})$, onde $\mathbf{S}_B$ é a matriz de dispersão intergrupos e $\mathbf{S}_T$ a total.
3. **Distância de Bhattacharyya** (1D, componente mais discriminante): mede a sobreposição entre distribuições de duas fases assumindo normalidade.

3.13.3 Balanceamento de Classes

A razão de desequilíbrio é definida como $r = n_{\max}/n_{\min}$, onde n_c é o número de observações da fase c . O limiar de aceitação adotado é $r \leq 1,5$.

3.13.4 Montagem do Dataset Final

O dataset final é construído pela junção interna (*inner join*) dos conjuntos selecionados das três modalidades nas chaves `subject_id` e `phase`, com média dos componentes por canal dentro de cada grupo. O arquivo resultante contém $n_{\text{EEG}} + n_{\text{ECG}} + n_{\text{EMG}}$ atributos nomeados com prefixo de modalidade.

3.14 Estrutura do Pipeline de Processamento

O pipeline projetado compreende dez estágios sequenciais. O estágio inicial corresponde à aquisição e validação de dados brutos. O segundo estágio contempla o cálculo de índices de qualidade (SQI) para a rejeição de segmentos. O terceiro estágio executa análises estatísticas e testes de hipótese. O quarto estágio aplica técnicas de filtragem e correção de artefatos. O quinto estágio realiza a segmentação temporal dos sinais em janelas. O sexto estágio executa a extração de atributos nos domínios do tempo e da frequência. O sétimo estágio realiza a engenharia de novos atributos. O oitavo estágio aplica redução de dimensionalidade por componentes principais. O nono estágio executa a seleção de variáveis informativas. O décimo estágio valida estatisticamente o conjunto final. Este relatório concentra-se na execução dos cinco primeiros estágios do projeto.

4 ANÁLISE DOS RESULTADOS

4.1 Aquisição e Carga de Dados

Os 16 sujeitos do dataset IEEE Multimodal Emotion Recognition foram processados integralmente pelo estágio inicial do pipeline de aquisição. A Tabela 3 resume os parâmetros técnicos e temporais obtidos para as modalidades de biossinais coletadas.

Tabela 3 – Sumário técnico dos biossinais adquiridos

Modalidade	Canais	Freq. Amostragem (Hz)	Duração (s)
EEG	8	512	60 – 145
ECG	1	250	60 – 260
EMG	1	250	60 – 260
fNIRS	2	16	60 – 145

4.2 Validação de Nyquist

Conforme planejado, todas as modalidades apresentam conformidade estrita com o teorema de amostragem de Nyquist, demonstrando razões entre a taxa de amostragem e a frequência máxima superiores ao limite teórico de 2,00. Esta conformidade assegura que os sinais foram amostrados adequadamente e podem ser submetidos a filtragens digitais e transformadas espectrais sem distorções de *aliasing* na banda de interesse, conforme detalhado na Tabela 4.

Tabela 4 – Parâmetros de validação conforme o teorema de Nyquist

Modalidade	f_s (Hz)	f_{max} (Hz)	$f_s/2f_{max}$	Conforme
EEG	512	50	5,12	✓
ECG	250	40	3,13	✓
EMG	250	100	1,25	✓
fNIRS	16	2	4,00	✓

4.3 Identificação de Falhas de Aquisição

A análise inicial de integridade identificou ocorrências de falhas em todos os 16 sujeitos do conjunto de dados, conforme consolidado na Tabela 5. Tais anomalias são decorrentes de limitações instrumentais ou instabilidades na interface sensor-pele.

Tabela 5 – Resumo das falhas de integridade identificadas

Categoria de Falha	Total de Ocorrências
Canais planos (ausência de sinal)	32
Clipping (saturação de amplitude)	66
Canais com alto nível de ruído	16

Conforme detalhado na Tabela 5, identificaram-se 114 canais com algum tipo de falha de aquisição. O *clipping* foi a anomalia mais frequente, representando 57,9% das ocorrências totais, o que sugere que o elevado *offset* DC do sistema Emotiv EPOC+ posiciona o sinal nas extremidades da faixa dinâmica do conversor A/D. Canais planos e ruidosos totalizaram 42,1% das falhas, indicando problemas na interface sensor-pele e interferências ambientais.

4.4 Inspeção Visual dos Registros Brutos

A visualização dos sinais brutos para o sujeito 000, abrangendo as quatro modalidades coletadas, é ilustrada na Figura 1. Para uma avaliação comparativa da qualidade entre participantes, a Figura 2 apresenta os registros do canal AF7 de EEG para todos os 16 sujeitos do experimento.

4.5 Avaliação de Qualidade do Sinal

No segundo estágio do pipeline, executou-se a avaliação automática de qualidade (SQI) através da análise segmentada dos sinais.

4.5.1 Calibração de Limiares por Modalidade

Os limiares de rejeição foram estabelecidos conforme descrito na Seção 3.5.5, calibrados para assegurar a robustez estatística das janelas de sinal. Observa-se que a modalidade fNIRS foi configurada com parâmetros de SNR extremamente permissivos devido à natureza do ruído intrínseco, enquanto o EEG exige maior estabilidade espectral.

A Tabela 6 apresenta os limiares de rejeição estabelecidos para cada modalidade.




Figura 1 – Visualização dos biossinais brutos para o sujeito 000: canais de EEG, ECG, EMG e fNIRS.

Tabela 6 – Limiares de rejeição por modalidade de biossinal

Modalidade	SNR mín. (dB)	Curtose máx.	Entropia mín.
EEG	-5,0	50,0	0,15
ECG	-3,0	100,0	0,30
EMG	-5,0	50,0	0,20
fNIRS	-50,0	100,0	0,01

4.5.2 Análise Quantitativa de Rejeição

A análise consolidada das taxas de rejeição por modalidade, considerando a totalidade dos 16 sujeitos, é apresentada na Tabela 7. Os resultados revelam disparidades significativas na estabilidade dos registros entre as modalidades. A taxa de rejeição do EEG ($\sim 5,0\%$) indica alta confiabilidade do sistema Emotiv EPOC+, enquanto o EMG apresentou perdas em mais de metade dos segmentos coletados ($\sim 56,0\%$). Por sua vez, o fNIRS alcançou taxa de rejeição de $97,5\%$, indicando que esta modalidade não possui integridade mínima para processamento.




Figura 2 – Panorama comparativo dos sinais de EEG (canal frontal AF7) para os 16 sujeitos do dataset.

Tabela 7 – Sumário das taxas de rejeição por modalidade

Modalidade	Segmentos Rejeitados	Taxa de Rejeição	Status
EEG	20/329	6,1%	Estável
ECG	118/334	35,3%	Crítico
EMG	187/334	56,0%	Instável
fNIRS	306/314	97,5%	Inutilizável

4.5.3 Inspeção de Artefatos Identificados

A Figura 3 ilustra a diferenciação automática entre segmentos aceitos e rejeitados para a modalidade de EEG do sujeito 000. O algoritmo foi capaz de identificar com precisão o artefato de alta curtose causado por desvio abrupto na amplitude, preservando os segmentos com morfologia fisiológica característica.

4.5.4 Comparação com Abordagens da Literatura

A Tabela 8 apresenta a comparação entre a metodologia proposta e abordagens consolidadas da literatura para avaliação de qualidade de biossinais.




Figura 3 – Avaliação de qualidade (SQI) para EEG: comparação entre segmento aceito e segmento rejeitado por alta curtose (instrumental).

Tabela 8 – Comparação entre metodologias de SQI

Trabalho	Modalidade	Métricas Utilizadas	Abordagem
(CUENA; LERGA, 2019)	ECG	Curtose, Assimetria	hOS-SQI
(ZHENG <i>et al.</i> , 2019)	EEG	6 métricas combinadas	EEGQI Framework
(TAYLOR <i>et al.</i> , 2022)	ECG	SQIp, SQIsnr, SQIkur	Análise de Robustez
Proposto	EEG/ECG/EMG	SNR, Curtose, Entropia	Thresholds Empíricos

4.6 Análise Estatística dos Sinais

No terceiro estágio do pipeline, realizou-se a caracterização estatística abrangente dos registros biosinais. A Tabela 9 apresenta os descritores consolidados para o primeiro sujeito (S000), demonstrando a variabilidade entre modalidades.

Tabela 9 – Caracterização estatística descritiva (Sujeito 000)

Modalidade	Canal	Média	Desvio Padrão	Assimetria	Curtose
EEG	AF7	-64254,6	3266,8	1,89	4,59
EEG	AF8	-67520,9	3297,9	1,89	4,91
ECG	ECG	-530,3	799,9	200,2	47055,6
EMG	EMG	8530,3	227,5	-0,26	30,23
fNIRS	HbO	$4,1 \times 10^{-9}$	$3,5 \times 10^{-7}$	-9,01	102,87

4.6.1 Resultados dos Testes de Normalidade

O teste de Shapiro-Wilk revelou que 100% (192/192) dos canais analisados em todos os 16 sujeitos divergem significativamente de uma distribuição normal ($p < 0,05$). Tais achados são corroborados pelos altos valores de curtose e assimetria, especialmente na modalidade ECG (Curtose $\approx 47055,6$), evidenciando a presença de picos R proeminentes e ruído impulsivo. A Figura 4 ilustra a distribuição de amplitude para o canal AF7 de EEG, comparando-a à curva normal teórica.





Figura 4 – Histograma de amplitudes do canal EEG-AF7 (Sujeito 000) com sobreposição de curva normal teórica.

Para avaliar visualmente o desvio da normalidade e a dispersão entre canais, a Figura 5 apresenta o gráfico Q-Q (*Quantile-Quantile*) e o *boxplot* comparativo para a modalidade EEG.

4.6.2 Testes de Homocedasticidade

A análise de homocedasticidade pelo teste de Levene entre os 8 canais de EEG demonstrou diferenças significativas de variância ($W = 7048,7, p < 0,05$). Este resultado sugere que os sensores de EEG, apesar de serem da mesma tecnologia (Emotiv EPOC+), apresentam níveis de ruído instrumental e impedância sensor-pele heterogêneos entre os locais de escalpo. Para a modalidade fNIRS, a falta de homocedasticidade entre HbO e



(a) Gráfico Q-Q (AF7)

(b) Boxplot por Canal

Figura 5 – Visualizações de diagnóstico estatístico para EEG (Sujeito 000): (a) avaliação de normalidade via quantis e (b) dispersão e *outliers* entre os 8 canais.

HbR ($p \approx 3,1 \times 10^{-39}$) reforça a instabilidade desta aquisição.

4.6.3 Correlação entre Canais e Modalidades

A matriz de correlação cruzada, apresentada na Figura 6, revela fortes interdependências entre os canais de EEG frontais (AF7 e AF8, $r > 0,80$), conforme esperado pela proximidade física dos sensores. Observou-se correlação desprezível entre as modalidades (ex: EEG vs ECG), indicando que os artefatos de pulsação cardíaca no registro de EEG não são dominantes no estado bruto.

Para avaliar a estabilidade das correlações em nível populacional, a Figura 7 apresenta a matriz agregada considerando o conjunto total de sujeitos analisados.

4.7 Limpeza e Correção de Sinais

No quarto estágio do pipeline, aplicou-se o conjunto de técnicas de filtragem e normalização conforme descrito na Seção 3.7. A Tabela 10 apresenta o resumo consolidado dos efeitos da limpeza para o sujeito 000, evidenciando reduções drásticas de variância e normalização de curtose.




Figura 6 – Matriz de correlação cruzada entre canais e modalidades para o Sujeito 000.

Tabela 10 – Efeitos da limpeza de sinais (Sujeito 000)

Modalidade	Var. Redução (%)	Curtose (antes)	Curtose (depois)	SNR (dB)	Amostras Winsorizadas
EEG (AF7)	99,9	4,60	3,44	12,36	7.418
EEG (PO7)	99,9	221,83	-1,12	-2,06	7.418
ECG	94,0	47055,61	1,30	6,94	6.488
EMG	99,8	30,23	-0,95	-1,26	6.488
fNIRS (HbO)	97,2	102,87	1,61	-60,00	232




Figura 7 – Matriz de correlação global agregada para todos os sujeitos do dataset.

4.7.1 Redução de Variância e Efeito de Cohen

Observou-se que os coeficientes d de Cohen calculados entre os estados antes e depois da limpeza indicam efeito de tamanho grande ($|d| > 0,8$) para todas as modalidades principais (EEG, ECG, EMG), confirmando que o processo de limpeza altera substancialmente a distribuição dos sinais. A variância reduziu-se em mais de 99% para EEG e EMG, e 94% para ECG, evidenciando a eficácia da combinação de filtragem e Winsorização na atenuação de ruído instrumental.

4.7.2 Normalização de Curtose

A curtose, que originalmente apresentava valores extremos (especialmente em ECG com $K \approx 47000$ devido aos picos R), foi normalizada para valores próximos de zero após a limpeza ($|K| < 3$), indicando distribuições aproximadamente mesocúrticas. Para o

canal PO7 de EEG, a curtose passou de 221,83 para -1,12, evidenciando a remoção de *spikes* instrumentais.

4.7.3 Interpolação de Lacunas

Identificou-se que os sinais não apresentaram lacunas significativas (gaps > 1s) que requeressem interpolação nos dados do sujeito 000. A função de interpolação foi executada corretamente em todos os demais sujeitos.

4.7.4 Manutenção de fNIRS

Conforme planejado na discussão do Estágio 3, a modalidade fNIRS foi mantida no pipeline de limpeza apesar de apresentar SNR constante de -60 dB e efeito de tamanho negligível. A justificativa para manutenção é que a filtragem passa-banda (0,01–0,1 Hz) reduz a variância em mais de 97% (Tabela 10), sugerindo que mesmo um sinal ruidoso pode beneficiar-se do pré-processamento para análises de tendências lentas.

Esta análise foi conduzida como prova de conceito metodológico, demonstrando a eficácia dos filtros mesmo em sinais de baixa qualidade. No entanto, para as fases subsequentes de extração de atributos e classificação (Estágios 6–10), o fNIRS será excluído do pipeline devido à sua taxa de rejeição superior a 95%.

4.8 Segmentação Temporal dos Sinais

No quinto estágio do pipeline, executou-se a segmentação temporal dos sinais limpos em janelas de 5 segundos com 50% de sobreposição. A Tabela 11 apresenta o consolidado da segmentação por modalidade.

Tabela 11 – Sumário da segmentação temporal por modalidade

Modalidade	Janelas Totais	Janelas Válidas	Taxa de Retenção
EEG (8 canais)	329	309	93,9%
ECG	334	216	64,7%
EMG	334	147	44,0%
fNIRS	314	8	2,5%

4.8.1 Análise de Estabilidade Intra-Janela

O teste de estacionariedade ADF e o coeficiente de variação (CV) foram aplicados a cada segmento para validar sua qualidade fisiológica. A Figura 8 ilustra a distribuição dos valores de CV por modalidade para o EEG.




Figura 8 – Distribuição do coeficiente de variação (CV) para EEG (Sujeito 000).

A Tabela 12 apresenta as métricas de estabilidade consolidadas para o sujeito 000, demonstrando que o EEG apresenta excelente uniformidade entre janelas (CV médio de 0,41%), enquanto o ECG apresenta maior variabilidade de amplitude (CV médio de 45,9%). A estacionariedade ADF indica que o ECG é fortemente estacionário (100%) devido à periodicidade cardíaca, enquanto o EEG é predominantemente não-estacionário (0%), coerente com a natureza dinâmica dos potenciais corticais.

Tabela 12 – Métricas de estabilidade intra-janela (Sujeito 000)

Modalidade	CV Médio (%)	CV Máx (%)	ADF Estacionário (%)
EEG	0,41	3,21	0,0
ECG	45,91	73,45	100,0
EMG	0,29	0,53	37,5
fNIRS	2045,44	6067,80	100,0

4.8.2 Variância Inter-Janelas

A análise de variância entre segmentos consecutivos revelou que o EEG apresenta menor variabilidade inter-janelas (indicando segmentos temporalmente consistentes), enquanto o EMG apresenta maior dispersão, refletindo a natureza descontínua da atividade muscular. A Figura 9 apresenta a análise comparativa para EEG.




Figura 9 – Variância inter-janelas para EEG (Sujeito 000).

4.8.3 Propagação de Máscaras de Qualidade

As máscaras de rejeição geradas no Estágio 2 foram propagadas para o janelamento, resultando nas taxas de rejeição apresentadas na Tabela 11. Observou-se que:

- **EEG:** 20 janelas rejeitadas (6,1%), principalmente por artefatos de piscada ocular e artefatos de movimento.
- **ECG:** 118 janelas rejeitadas (35,3%), principalmente por baixa SNR e variabilidade excessiva.
- **EMG:** 187 janelas rejeitadas (56,0%), indicando instabilidade na interface sensor-pele durante o protocolo de indução emocional.
- **fNIRS:** 306 janelas rejeitadas (97,5%), confirmando a exclusão desta modalidade do pipeline.

4.8.4 Visualização das Janelas

A Figura 10 apresenta a representação visual das janelas segmentadas para o sujeito 000 (EEG), demonstrando a aplicação correta do janelamento com sobreposição.




Figura 10 – Segmentação temporal com janelas de 5s e 50% de sobreposição para EEG (Sujeito 000).

4.8.5 Cache de Segmentos Gerados

Ao final do estágio, foram gerados 64 arquivos **.npz** (4 modalidades $\times$ 16 sujeitos) contendo os segmentos válidos. Cada arquivo preserva:

- Sinais particionados com metadados temporais.
- Máscaras de qualidade propagadas do SQL.
- Métricas de estabilidade por janela.

Estes arquivos constituem a entrada para o Estágio 6 de extração de atributos, otimizando o tempo de processamento ao evitar reproprocessamento de sinais brutos.

4.8.6 Análise Inter-Sujeitos e Padrões Observados

A análise da variabilidade entre os 16 sujeitos revelou padrões distintos por modalidade, conforme apresentado na Tabela 13. As observações mais importantes revelam também particularidades de cada sujeito para com os sinais coletados, além de análise

inter-modalidades e inter-janelas.

Tabela 13 – Retenção de janelas por sujeito e modalidade

Sujeito	EEG		ECG		EMG		fNIRS	
	Total	Válidas	Total	Válidas	Total	Válidas	Total	Válidas
s000	28	23 (82%)	51	16 (31%)	51	24 (47%)	28	4 (14%)
s001	23	22 (96%)	20	17 (85%)	20	7 (35%)	23	2 (9%)
s002	15	14 (93%)	15	14 (93%)	15	0 (0%)	15	0 (0%)
s003	16	15 (94%)	16	2 (12%)	16	13 (81%)	16	0 (0%)
s004	20	19 (95%)	16	4 (25%)	16	10 (62%)	20	0 (0%)
s005	21	20 (95%)	18	17 (94%)	18	17 (94%)	21	0 (0%)
s006	20	19 (95%)	19	2 (11%)	19	8 (42%)	20	1 (5%)
s007	16	15 (94%)	17	9 (53%)	17	2 (12%)	16	0 (0%)
s008	19	18 (95%)	20	19 (95%)	20	8 (40%)	19	0 (0%)
s009	20	19 (95%)	20	19 (95%)	20	3 (15%)	20	0 (0%)
s010	14	13 (93%)	15	14 (93%)	15	4 (27%)	14	0 (0%)
s011	24	23 (96%)	24	23 (96%)	24	21 (88%)	24	0 (0%)
s012	23	22 (96%)	24	23 (96%)	24	10 (42%)	23	1 (4%)
s013	26	25 (96%)	20	0 (0%)	20	10 (50%)	26	0 (0%)
s014	25	24 (96%)	23	22 (96%)	23	10 (43%)	25	0 (0%)
s015	19	18 (95%)	16	15 (94%)	16	0 (0%)	4	0 (0%)

A análise por sujeito revela padrões de qualidade heterogêneos entre participantes. O sujeito **s005** apresentou o melhor perfil global (EEG 95%, ECG 94%, EMG 94%), enquanto **s011** foi o único a superar 88% em todas as três modalidades ativas. Em contraste, **s000** registrou as maiores perdas multimodais simultâneas: EEG 82% (menor entre todos), ECG 31% e EMG 47%, sugerindo problemas de fixação do equipamento durante o protocolo.

No ECG, três sujeitos apresentaram rejeição quase total: **s003** (88% rejeitado), **s006** (89%) e, criticamente, **s013** (100% rejeitado), que foi excluído do dataset cruzado final por ausência de janelas ECG válidas. Esses casos indicam provável desconexão do eletrodo ou interferência de movimento de alta amplitude. No EMG, os sujeitos **s002** e **s015** tiveram 100% de rejeição — falhas completas de aquisição que os excluem igualmente do dataset cruzado. Os sujeitos **s007** (88% rejeitado) e **s009** (85% rejeitado) apresentaram EMG com baixíssima retenção, consistente com a ausência de tarefa motora explícita no protocolo. Para o fNIRS, todos os 16 sujeitos tiveram retenção inferior a 15%, confirmando a exclusão definitiva desta modalidade.

1. **EEG:** A taxa de retenção foi consistentemente alta (82–96%), com média de 93,9%.

O sujeito s000 apresentou a menor taxa (82%), possivelmente devido a artefatos de movimento prolongados durante o protocolo. Os coeficientes de variação (CV) foram

extremamente baixos (média de 0,41% para s000), indicando estabilidade temporal excepcional do sinal EEG.

2. **ECG:** Observou-se alta variabilidade inter-sujeitos. Quatro sujeitos (s003, s004, s006, s013) apresentaram taxa de rejeição superior a 70%, sugerindo problemas crônicos de contato sensor ou arritmias cardíacas. Em contraste, seis sujeitos (s001, s002, s005, s008, s009, s011) alcançaram retenção superior a 85%. O teste ADF indicou que 97,7% das janelas de ECG são estacionárias, coerente com a periodicidade cardíaca quase-determinística.
3. **EMG:** Dois sujeitos (s002, s015) apresentaram 0% de janelas utilizáveis, indicando falhas completas na aquisição. A taxa média de estacionariedade ADF foi baixa (14,3%), refletindo a natureza descontínua e não-estacionária da atividade eletromiográfica durante a indução emocional.
4. **fNIRS:** Confirmou-se a exclusão de fNIRS para todos os sujeitos, com apenas 8 janelas válidas (2,5%) no dataset completo. Os valores de CV foram extremos (média de 2045%), indicando variabilidade não-fisiológica nos dados.
5. **Correlação Inter-Modalidades:** A correlação de Pearson entre as taxas de retenção de diferentes modalidades foi fraca (EEG-ECG: $r = 0,24$; ECG-EMG: $r = -0,25$), indicando que sujeitos com boa qualidade de EEG não necessariamente apresentam boa qualidade de ECG ou EMG. Isto sugere que as fontes de artefato são específicas por modalidade e não correlacionadas com o estado geral do participante.
6. **Variância Inter-Janelas:** O ECG apresentou maior variância entre janelas consecutivas ($\sigma^2 = 0,012$) em comparação com EEG ($\sigma^2 = 0,003$) e EMG ($\sigma^2 = 0,0004$), refletindo a maior dinâmica temporal do sinal cardíaco.

4.9 Discussão dos Achados

A análise integrada dos resultados indica que os sinais de EEG apresentam a maior estabilidade qualitativa, com baixas taxas de rejeição. No entanto, as modalidades de ECG e EMG demonstraram alta dependência da qualidade do contato sensor-pele e de artefatos de movimento, resultando em perdas significativas de janelas temporais.

A rejeição de hipótese nula nos testes de normalidade (Shapiro-Wilk) e homocedasticidade (Levene) justifica a adoção de estratégias de processamento robusto nos estágios subsequentes. Em particular, a filtragem espacial e a normalização de variância

(Z-score por canal) tornam-se indispensáveis antes da extração de atributos, para mitigar os vieses introduzidos pela heterogeneidade instrumental e pelos artefatos de cauda pesada.

A modalidade de fNIRS apresentou taxa de rejeição próxima à totalidade ($> 95\%$), confirmando falhas estruturais na aquisição original do dataset (distâncias entre fonte e detector nulas). Tais achados, aliados à curtose anômala (> 100), justificam a exclusão definitiva do fNIRS nas etapas de filtragem (Estágio 4) e extração de atributos (Estágio 6), otimizando o pipeline para os biossinais que mantêm integridade fisiológica mínima.

4.10 Extração de Atributos

O sexto estágio do pipeline executou a extração de atributos sobre os 64 arquivos de segmentos gerados no Estágio 5, processando as três modalidades ativas (EEG, ECG e EMG) para todos os 16 sujeitos.

4.10.1 Matriz de Atributos Gerada

Ao total, foram extraídas 2.780 observações (janela $\times$ canal), distribuídas conforme a Tabela 14.

Tabela 14 – Resumo da matriz de atributos extraída no Estágio 6

Modalidade	Atributos	Observações	Descrição adicional
EEG	18	2.417	9 temporais + 4 espectrais + 5 bandas
ECG	20	216	13 gerais + 7 HRV (tempo e freq.)
EMG	13	147	9 temporais + 4 espectrais
Total	—	2.780	3 modalidades, 16 sujeitos

4.10.2 Atributos Temporais e Espectrais

A Figura 11 apresenta os boxplots dos atributos de EEG agregados sobre todos os sujeitos e janelas. Observa-se elevada dispersão nos atributos de potência de banda, refletindo a variabilidade inter-sujeito característica dos registros de EEG emocional.




Figura 11 – Distribuição dos atributos de EEG (boxplots) agregados sobre todos os sujeitos e janelas válidas.




Figura 12 – Distribuição dos atributos de ECG, incluindo os atributos de HRV no domínio do tempo e da frequência.




Figura 13 – Distribuição dos atributos de EMG, com ênfase nos descritores temporais e espectrais.

4.10.3 Correlação entre Atributos

A Figura 14 exibe o mapa de calor das correlações de Pearson entre os atributos de EEG. Destaca-se a alta correlação entre *hjorth_activity* e variância ($r \approx 1,00$), o que é esperado pela definição dos parâmetros de Hjorth, e entre as potências das bandas adjacentes, evidenciando a continuidade espectral dos sinais.

4.10.4 Potência por Bandas de EEG

A Figura 15 apresenta as potências médias por banda de frequência para cada sujeito. A banda beta (13–30 Hz) dominou com potência média de $41,7 \mu V^2/\text{Hz}$, seguida pela banda alpha (8–13 Hz) com $19,0 \mu V^2/\text{Hz}$. Esta distribuição é consistente com a literatura de EEG emocional, onde a banda beta é associada ao processamento cognitivo e à resposta ao estímulo visual. Destaca-se que o sujeito s000 apresenta potência na banda




Figura 14 – Mapa de calor das correlações de Pearson entre atributos de EEG.

delta aproximadamente 80 vezes superior à mediana dos demais sujeitos, indicando a presença de artefatos de baixa frequência persistentes neste participante — artefato já identificado no Estágio 1 como canal com alto nível de ruído.

4.10.5 Variabilidade da Frequência Cardíaca (ECG)

Os atributos de HRV extraídos para o ECG revelaram padrões fisiologicamente plausíveis. O intervalo RR médio foi de $731,3 \pm 94,8$ ms (correspondente a ≈ 82 bpm), onde o desvio padrão reflete a variação entre janelas; o SDNN médio intra-janela foi de 105,4 ms e o RMSSD médio de 132,4 ms. A alta variabilidade observada no RMSSD é consistente com a natureza dos registros de curta duração (janelas de 5 s), onde a estimativa HRV tem maior incerteza estatística. Os atributos espectrais de HRV (lf_power , hf_power e lf_hf_ratio) não foram computáveis neste estágio: janelas de 5 s fornecem resolução espectral de apenas 0,2 Hz, insuficiente para resolver as bandas LF (0,04–0,15 Hz) e HF




Figura 15 – Potência média por banda de frequência (delta, theta, alpha, beta, gamma) para cada sujeito.

(0,15–0,4 Hz) da análise espectral de HRV, que requer registros de pelo menos 2 minutos (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996).

4.10.6 Atributos de EMG

Para o EMG, o RMS médio foi de $5.971 \mu V$, a frequência média de 27,4 Hz e a frequência mediana de 20,2 Hz. A baixa frequência dominante indica que a atividade muscular capturada é principalmente de baixa intensidade, coerente com o protocolo experimental de indução emocional passiva (sem tarefa motora explícita).

4.11 Engenharia de Atributos

O sétimo estágio enriqueceu a matriz de atributos com novos descritores derivados, normalizações e análises de qualidade, conforme descrito na Seção 3.10.

4.11.1 Matriz Enriquecida

A Tabela 15 resume o número de colunas adicionadas por modalidade após a engenharia de atributos.

Tabela 15 – Colunas adicionadas pela engenharia de atributos por modalidade

Modalidade	Orig.	+ Razões	+ Norm.	+ Δ/Δ^2
EEG	18	5	23	10
ECG	20	—	20	10
EMG	13	—	13	10

4.11.2 Razões de Potência de Banda EEG

A Figura 16 apresenta a distribuição das razões de potência por fase experimental. O índice alpha/beta foi o atributo de maior poder discriminante entre fases ($F = 23,16$, $p < 0,001$), seguido pela razão theta/beta ($F = 17,41$, $p < 0,001$). Durante a fase de estimulação observa-se redução do índice alpha/beta em relação à linha de base, coerente com o aumento da atividade cortical reportado na literatura de EEG emocional.




Figura 16 – Razões de potência de banda EEG por fase experimental.

4.11.3 Discriminabilidade entre Fases

A Figura 17 apresenta as F -estatísticas ANOVA para os 20 atributos mais discriminantes de cada modalidade. Para o EEG, 6 atributos foram estatisticamente significativos ($p < 0,05$): *alpha_beta_ratio* ($F = 23,16$), *theta_beta_ratio* ($F = 17,41$), *mav* ($F = 9,32$), *rms* ($F = 9,32$), *mean_freq* ($F = 7,78$) e *spectral_entropy* ($F = 4,78$), sendo os dois primeiros as razões espectrais recém-criadas. Para ECG e EMG, nenhum atributo atingiu significância estatística ($F < 3,0$), o que é consistente com o protocolo de indução emocional passiva, que não induz variações autonômicas ou musculares sistemáticas suficientes para discriminar fases em janelas de 5 s.




Figura 17 – Discriminabilidade de fase (ANOVA F -estatística) por atributo e modalidade.

4.11.4 Análise de Redundância

A análise de correlação de Pearson identificou 7 pares redundantes no EEG ($|r| \geq 0,95$), 2 no EMG e nenhum no ECG, conforme ilustrado na Figura 18. Os pares redundantes no EEG concentram-se entre *hjorth_activity* e variância (correlação perfeita por definição) e entre as potências de bandas espectralmente adjacentes. Estes pares serão candidatos à remoção no Estágio 9 de seleção de atributos.

4.12 Redução de Dimensionalidade

O oitavo estágio aplicou PCA sobre as matrizes agregadas do Estágio 7, conforme descrito na Seção 3.12. A Tabela 16 resume os resultados por modalidade.

Tabela 16 – Resultados da PCA por modalidade

Modalidade	Obs.	Atrib. entrada	Descartados	PC@90%	PC@95%	Var. PC1	Var. PC2
EEG	375	220	4	26	38	18,7%	15,7%
ECG	41	172	28	18	22	17,9%	11,3%
EMG	37	140	4	15	18	18,9%	16,1%

4.12.1 EEG

Para o EEG, 375 observações (sujeito $\times$ canal $\times$ fase) foram decompostas a partir de 220 atributos (4 colunas *zcr_norm* descartadas por excesso de NaN). O primeiro componente explica 18,7% da variância total e o segundo 15,7%; os cinco primeiros




Figura 18 – Mapa de calor de redundância entre atributos de EEG (correlação de Pearson).

componentes acumulam 54,0% e os dez primeiros 71,1%. São necessários 26 componentes para atingir 90% e 38 para 95% de variância explicada, representando uma compressão de 83% (220 $\rightarrow$ 38 dimensões).

A análise das cargas do PC1 revela que os atributos de maior peso são derivados de segunda ordem dos poderes espectrais (*delta2_alpha_power_std*, *delta2_alpha_power_max*, *delta2_beta_power_std*), indicando que a principal fonte de variância entre observações é a instabilidade temporal dos poderes nas bandas alfa e beta. O PC2 é dominado pelos agregados normalizados de máximo (*total_power_norm_max*, *theta_power_norm_max*), capturando contrastes de amplitude entre sujeitos. A projeção das observações no plano PC1 $\times$ PC2 (Figura 21) revela sobreposição parcial entre as três fases, consistente com os resultados de discriminabilidade do Estágio 7 e com a natureza distribuída da informação de fase no espaço PCA.




Figura 19 – Diagrama de cotovelo para o EEG.




Figura 20 – Curva de variância acumulada para o EEG.

4.12.2 ECG e EMG

Para o ECG, 28 das 200 colunas de entrada foram descartadas por excesso de NaN (24 relativas às bandas LF/HF e seus derivados, cujos valores são nulos devido à limitação de resolução espectral das janelas de 5 s). A decomposição resultou em 41 componentes (limitada pelo número de observações), com 18 componentes para 90% e 22 para 95% de variância. O PC1 do ECG é dominado por atributos de mobilidade de Hjorth e seus deltas ($hjorth_mobility_std$, $r = 0,167$), refletindo variabilidade na morfologia do sinal cardíaco.

Para o EMG, 37 observações e 140 atributos (4 descartados) resultam em 15 e




Figura 21 – Dispersão PC1 × PC2 para EEG por fase experimental.

18 componentes para os limiares de 90% e 95%, respectivamente. O EMG apresenta a maior variância nos primeiros cinco componentes (61,6%), sugerindo menor redundância na estrutura dos atributos em relação ao EEG.




Figura 22 – Mapa de cargas PCA para EEG: primeiros 5 componentes e os 15 atributos de maior carga absoluta.

4.13 Seleção de Atributos

O nono estágio aplicou três famílias de seleção sobre os componentes principais produzidos pelo Estágio 8, conforme descrito na Seção 3.11. A Tabela 17 apresenta os

resultados consolidados por modalidade.

Tabela 17 – Resultados da seleção de atributos por modalidade

Modalidade	PCs entrada	Sig. Bonf.	RFE ótimo	L1 não-zero	Consenso	Acc. CV
EEG	38	2	36	38	36	65,6%
ECG	22	0	10	19	10	36,7%
EMG	18	0	16	15	16	53,9%

4.13.1 EEG

Para o EEG, o RFECV determinou que o subconjunto ótimo contém 36 dos 38 componentes, atingindo acurácia de validação cruzada de 65,6% para três classes (chance = 33,3%). Apenas 2 componentes sobreviveram à correção de Bonferroni (PC29, $F = 16,53$; PC6, $F = 9,05$), refletindo a elevada multiplicidade dos 38 testes simultâneos. O componente de maior destaque é o PC29, que apresenta $f^2 = 0,089$ (efeito pequeno a médio) e informação mútua de 0,117. O fato de o RFECV reter 36 dos 38 componentes sugere que a informação de fase está distribuída difusamente pelo espaço PCA do EEG, sem concentração em poucos componentes dominantes.




Figura 23 – F -estatísticas ANOVA por componente principal para EEG.

4.13.2 ECG e EMG

Para o ECG, nenhum componente atingiu significância estatística após correção de Bonferroni, e a acurácia RFECV de 36,7% é essencialmente ao nível do acaso, corroborando os resultados dos Estágios 7 e 8 que indicam ausência de discriminabilidade




Figura 24 – Curva RFECV para EEG: acurácia de validação cruzada por número de componentes retidos.

de fase no sinal cardíaco com janelas de 5 s. O subconjunto consenso retém 10 dos 22 PCs com base no critério RFE.

O EMG apresenta acurácia moderada de 53,9%, com o componente PC15 destacando-se como o mais informativo: $f^2 = 0,260$ (equivalente a $\eta^2 = 0,207$ pela relação $\eta^2 = f^2/(1 + f^2)$; efeito médio, maior valor entre todas as modalidades), consistente com a hipótese de que a atividade muscular periférica reflete em algum grau as fases de estimulação emocional. Nenhum componente de EMG ou ECG sobreviveu à correção de Bonferroni.




Figura 25 – Ranking de consenso para EEG: posição dos 15 melhores componentes nos métodos ANOVA, MI, L1-coeficiente e RFE.

4.14 Validação Estatística Final

O décimo estágio verificou a prontidão do conjunto de dados conforme descrito na Seção 3.13. A Tabela 18 apresenta os resultados consolidados por modalidade.

Tabela 18 – Resultados da validação estatística final por modalidade

Modalidade	Obs.	Atrib.	VIF máx.	Raz. imbalan.	η^2 (top PC)	Pronto
EEG	375	36	1,000	1,00	0,082	✓
ECG	41	10	1,000	1,08	0,163	✓
EMG	37	16	1,000	1,27	0,207	✓

4.14.1 Multicolinearidade

O VIF de todos os componentes principais é exatamente 1,000 para as três modalidades, confirmando a ortogonalidade matemática garantida pela PCA. Nenhum componente apresenta redundância linear com os demais, validando a integridade da etapa de redução de dimensionalidade.

4.14.2 Separabilidade de Fase

A Figura 26 ilustra as curvas de densidade por fase para os três primeiros componentes do EEG. O componente PC29 apresenta o maior poder discriminante individual ($F = 16,53$, $\eta^2 = 0,082$), sendo o único componente EEG significativo após correção de Bonferroni. O traço de Pillai multivariado do EEG é de 0,516, indicando separabilidade moderada entre as três fases.

O EMG apresenta o maior η^2 por componente ($\eta^2 = 0,207$ para PC15) e a maior distância de Bhattacharyya entre fases ($d_B = 0,376$ entre linha de base e recuperação), sugerindo que a atividade muscular periférica reflete diferenças estruturais entre as condições experimentais. O ECG permanece com separabilidade limitada ($F_{\max} = 3,71$, $d_B \leq 0,258$), consistente com os resultados dos Estágios 7–9.

4.14.3 Balanceamento de Classes

O EEG apresenta balanceamento perfeito entre fases (125 observações cada, razão = 1,00). O ECG possui razão de 1,08 e o EMG de 1,27, ambos dentro do limiar de




Figura 26 – Curvas de densidade KDE por fase experimental para os três componentes EEG mais discriminativos (PC29, PC13, PC6).

1,5 adotado. Nenhuma modalidade requer reamostragem para equilibrar classes.




Figura 27 – Balanceamento de classes por fase experimental para o EEG.

4.14.4 Dataset Final

O dataset cruzado entre modalidades foi construído pela junção interna nas chaves `subject_id` e `phase`, resultando em 13 sujeitos comuns às três modalidades, 30 observações e 62 atributos ($36_{\text{EEG}} + 10_{\text{ECG}} + 16_{\text{EMG}}$). Os 3 sujeitos excluídos da junção correspondem àqueles sem dados de ECG (s013) ou EMG (s002, s015) desde o Estágio 5. O conjunto EEG isolado (375 observações, 36 atributos) permanece disponível para

experimentos de classificação unimodal.

O pipeline de 10 estágios está completo. O dataset final está disponível em `output/stage10_validation/data/dataset_final.csv`, pronto para aplicação de classificadores como SVM, k -NN, *Random Forest* e redes neurais.

5 CONCLUSÕES E TRABALHOS FUTUROS

REFERÊNCIAS

- CUENA, R.; LERGA, J. A tool for the real-time evaluation of ecg signal quality and activity classification based on higher-order-statistics. **Biomedical Signal Processing and Control**, Elsevier, v. 52, p. 332–340, 2019.
- LEVENE, H. Robust tests for equality of variances. **Contributions to probability and statistics**, v. 1, p. 278–292, 1960.
- NASER, M.; OTHERS. **Dataset of Multi-Modal Physiological Signals (fNIRS, EEG, ECG, EMG) Recorded Across Different Emotional States**. 2023. IEEE DataPort. Disponível em: <<https://ieee-dataport.org/documents/dataset-multi-modal-physiological-signals-fnirs-ecg-emg-recorded-across-different>>.
- SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). **Biometrika**, JSTOR, v. 52, n. 3/4, p. 591–611, 1965.
- Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology. Heart rate variability: standards of measurement, physiological interpretation and clinical use. **Circulation**, American Heart Association, v. 93, n. 5, p. 1043–1065, 1996.
- TAYLOR, S.; JAQUET, C.; LEVINE, J.; FINLAY, D.; NUGENT, C. Robustness of electrocardiogram signal quality indices. **Journal of the Royal Society Interface**, Royal Society, v. 19, n. 189, p. 20220012, 2022.
- ZHENG, W.; LIU, W.; OZTURK, Y.; BHATTI, P. Good data? the eeg quality index for automated assessment of signal quality. **IEEE Transactions on Biomedical Engineering**, IEEE, v. 66, n. 12, p. 3558–3567, 2019.